

Laudo Comparativo: RAG Puro vs Agente com Dados Estruturados

Projeto Assistente de Editais — Abril 2026

1. Objetivo

Comparar o desempenho de duas arquiteturas de resposta para perguntas sobre editais de concursos publicos: (A) RAG puro, onde o agente possui apenas busca semantica no texto completo dos editais, e (B) a solucao em desenvolvimento (branch develop), onde o agente dispoe de dados estruturados extraídos via LLM, busca semantica complementar, resumos pre-gerados e tools especializadas por tipo de consulta.

2. Metodologia

Foram elaboradas 10 perguntas cobrindo diferentes tipos de consulta: dados pontuais (salario, jornada), dados numericos especificos (vagas PcD, notas minimas), interpretacao de regras (ingles elimina, calculadora, relógio), raciocinio temporal (inscricoes abertas), contagem (blocos do conteudo programatico) e listagem ordenada (criterios de desempate). As respostas de referencia foram extraidas manualmente do edital BNDES 01/2024. As mesmas perguntas foram submetidas a ambas as arquiteturas sobre o mesmo edital.

3. Resultados

#	Pergunta	Resposta correta (resumida)	RAG Puro	Develop
1	Salario	R\$ 20.900	OK	OK
2	Vagas PcD	3 PcD imediatas	Erro Nao achou	Erro Base invertida (6)
3	Requisito graduacao	Qualquer graduacao de nivel superior	Erro Inventou cursos de outra enfase	OK Texto literal
4	Ingles elimina?	Nao, apenas classificatorio	Erro Disse que sim, misturou com Port.	Parcial Acertou que nao mas inventou nota min.
5	Blocos conteudo	13 blocos	Erro Disse 6	OK 13 listados
6	Nota min. Transversais	10 pontos	OK	OK
7	Relogio na prova	Nao permitido	OK	OK
8	Inscricoes abertas?	Nao, encerraram em 08/2024	Erro Disse que sim	Erro Disse que ainda nao abriram
9	Jornada	35h semanais	OK	OK
10	Criterios desempate	7 criterios ordenados	Erro So 2, incorretos	Erro So 2, incompletos

	RAG Puro	Develop
Acertos	4/10	6/10
Erros	6/10	3/10
Parcial	0/10	1/10

4. Analise

4.1 Ganhos da arquitetura com dados estruturados

A branch develop apresentou ganho expressivo em perguntas factuais estruturadas. O caso mais ilustrativo é a pergunta sobre requisitos de graduação (pergunta 3): o RAG puro retornou trechos do edital contendo requisitos de múltiplas ênfases (Análise de Sistemas, Engenharia, etc.) e o LLM mesclou todas na resposta, gerando uma lista de cursos específicos inexistente para Ciência de Dados. A branch develop consultou o campo estruturado e retornou o texto literal do edital.

O mesmo padrão se repetiu na pergunta sobre conteúdo programático (pergunta 5): o RAG puro não tem mecanismo para contar blocos — retorna trechos e o LLM estimou 6. A develop consultou o campo estruturado que lista os 13 blocos extraídos na ingestão.

Esses resultados são consistentes com as limitações conhecidas de sistemas RAG operando sobre documentos longos e multi-seção. A fragmentação do documento em chunks de tamanho fixo destrói a estrutura hierárquica do edital (seções, ênfases, anexos), e o retrieval baseado em similaridade semântica não distingue entre seções destinadas a diferentes cargos. A literatura identifica esses problemas como inerentes a arquiteturas RAG sem enriquecimento de metadados ou estruturação prévia dos dados (Liu et al., 2024; Huang et al., 2025).

4.2 Erros compartilhados

Ambas as arquiteturas falharam em três perguntas. Na pergunta sobre inscrições (pergunta 8), nenhuma comparou as datas do cronograma com a data atual — o RAG puro afirmou que as inscrições estavam abertas, e a develop afirmou que ainda não tinham aberto, ambas respostas incorretas considerando que hoje é abril de 2026 e as inscrições encerraram em agosto de 2024. Na pergunta sobre critérios de desempate (pergunta 10), ambas retornaram apenas 2 dos 7 critérios, indicando que nem o RAG encontra o trecho completo nem o JSON foi extraído com todos os critérios. Na pergunta sobre vagas PcD (pergunta 2), o RAG não encontrou a informação e a develop retornou valor incorreto devido à inversão de campos na extração.

4.3 Fragilidades residuais do RAG

O RAG puro apresentou dois tipos de erro característicos. O primeiro é a contaminação entre seções: ao buscar 'requisitos de formação', os chunks mais similares semanticamente podem vir de qualquer ênfase do edital, pois todas as seções de requisito usam vocabulário semelhante. Sem metadados indicando a qual ênfase o chunk pertence, o retrieval não tem como distingui-los. O segundo é a tendência à confabulação quando o trecho retornado é insuficiente: na pergunta sobre inglês, o RAG trouxe um trecho mencionando notas mínimas de Língua Portuguesa e o LLM atribuiu essa regra ao inglês. Esses erros não são eliminados com mais chunks ou modelos maiores — são limitações arquiteturais do RAG sem estruturação.

5. Conclusão

A arquitetura com dados estruturados e tools especializadas (branch develop) superou o RAG puro tanto quantitativamente (6 vs 4 acertos em 10 perguntas) quanto qualitativamente, com respostas

mais precisas e menos confabulacoes. O principal ganho vem da separacao entre informacoes estruturadas (consultadas por campo) e informacoes nao estruturadas (acessadas via RAG). Essa separacao evita que o agente dependa de similaridade semantica para dados factuais, onde ela e mais fragil. Os erros remanescentes na develop sao de naturezas distintas (dado errado na base, ausencia de raciocinio temporal, extracao incompleta) e serao tratados nas proximas etapas de desenvolvimento.

6. Referencias

Liu, N. F. et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12, 157-173. DOI: 10.1162/tacl_a_00638.

Huang, L. et al. (2025). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Transactions on Information Systems*, 43(5), 1-55. DOI: 10.1145/3703155.