

Levantamento Bibliografico: Desafios na Extracao Estruturada de Documentos Longos com LLMs

Documentacao tecnica para suporte ao TCC

1. Problema Enfrentado

Ao utilizar LLMs (Large Language Models) para extrair informacoes estruturadas de documentos longos (editais de concurso publico brasileiro, com 30 a 50 paginas), observamos dois comportamentos falhos sistematicos:

Omissao seletiva: O LLM lista apenas uma fracao dos itens solicitados. Em nosso caso, ao pedir a lista completa de blocos do conteudo programatico (13 blocos no edital original), o modelo retornou apenas 4. O comportamento nao e truncamento sequencial - o modelo seleciona alguns itens e omite outros de forma aparentemente arbitraria.

Parafrase distorcida: Em vez de copiar literalmente informacoes factuais, o LLM parafraseia e introduz imprecisoas. O edital especifica como requisito 'qualquer graduacao de nivel superior', mas o modelo extraiu 'graduacao em Ciencia de Dados ou areas correlatas' - uma restricao que nao existe no documento original.

Esses comportamentos persistem mesmo com prompts explicitos instruindo extracao literal e completa. O problema e agravado quando o documento e longo e a informacao desejada esta dispersa por diferentes secoes.

2. Contexto Tecnico

O sistema em desenvolvimento e um assistente de editais de concursos publicos na area de Ciencia de Dados. A pipeline de ingestao consiste em: (1) extracao de texto do PDF com pdfplumber; (2) envio do texto ao LLM com prompt solicitando JSON estruturado; (3) validacao com Pydantic; (4) persistencia em SQLite. Os modelos utilizados foram GPT-4o-mini (OpenAI) e Gemini 2.5 Flash (Google).

A literatura identifica tres fenomenos que convergem para explicar o comportamento observado: alucinacao por infidelidade (faithfulness hallucination), o efeito 'Lost in the Middle' em contextos longos, e limitacoes na geracao de outputs estruturados complexos.

3. Referencias Bibliograficas

3.1 Alucinacao em LLMs - Surveys Gerais

Huang, L. et al. (2025). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Transactions on Information Systems*.

Survey publicado em periodico de alto impacto. Propoe taxonomia de alucinacoes dividida em factuality hallucination e faithfulness hallucination, e analisa fatores contribuintes ao longo de todo o ciclo de vida do LLM. Relevante para classificar o tipo de erro que observamos (faithfulness hallucination: o modelo gera conteudo sintaticamente correto mas infiel ao documento fonte).

<https://dl.acm.org/doi/10.1145/3703155>

Alharbi, A. et al. (2026). A Comprehensive Survey of Hallucination in Large Language Models. *arXiv:2510.06265*.

Apresenta taxonomia estruturada de causas, metodos de deteccao (retrieval, uncertainty, embedding, learning, self-consistency) e mitigacao (prompt, retrieval, reasoning, model-centric). Inclui analise de contextos multilingues, frequentemente ignorados na literatura.

<https://arxiv.org/abs/2510.06265>

3.2 Alucinacao em Extracao de Informacao

AMIA (2024). Clinical Information Extraction with Large Language Models: A Case Study on Organ Procurement. *AMIA Annual Symposium Proceedings, 2024*.

Estudo de caso que documenta o mesmo problema observado em nosso projeto: LLMs gerando informacao plausivel mas incorreta durante extracao numerica de notas clinicas. Propoe heurísticas de combate a alucinacao e valida em 298 documentos. Demonstra que estrategias de few-shot com valores raros reduzem confabulacao.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC12099322/>

Anh-Hoang, T. et al. (2025). Survey and analysis of hallucinations in large language models: attribution to prompting strategies or model behavior. *Frontiers in Artificial Intelligence*.

Propoe framework para determinar se a alucinacao vem do prompt (prompt-induced) ou do comportamento intrinseco do modelo (model-internal). Avalia GPT-4, LLaMA 2 e DeepSeek. Conclui que prompts estruturados como chain-of-thought reduzem alucinacoes em cenarios sensiveis ao prompt, mas limitacoes intrinsecas persistem.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC12518350/>

3.3 LLMs para Extracao de Informacao - Surveys

Xu, D. et al. (2024). Large language models for generative information extraction: a survey. *Frontiers of Computer Science*, Springer.

Survey abrangente sobre uso de LLMs para extracao de informacao, incluindo entidades, relacoes e eventos. Cobre abordagens de prompting, fine-tuning e destilacao de conhecimento.

<https://link.springer.com/article/10.1007/s11704-024-40555-y>

Li, H. et al. (2025). A Survey of Generative Information Extraction. *COLING 2025*.

Identifica que metodos de extracao com LLMs funcionam bem em textos curtos ou sentencas, mas enfrentam dificuldades significativas com documentos longos (Long Document IE). Diretamente relevante para nosso caso.

<https://aclanthology.org/2025.coling-main.324.pdf>

3.4 O Efeito 'Lost in the Middle'

Liu, N. F. et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*.

Demonstra que LLMs tem dificuldade em acessar e utilizar informacao posicionada no meio de contextos longos, com desempenho significativamente melhor para informacoes no inicio e no final. Explica por que nosso LLM captura enfases do inicio e do final do edital mas omite as do meio do documento.

Referencia principal: [arXiv:2307.03172](https://arxiv.org/abs/2307.03172)

3.5 Benchmarks de Alucinacao em Documentos

Bang, Y. et al. (2025). HalluLens: LLM Hallucination Benchmark. *ACL 2025*.

Benchmark que distingue alucinacoes intrinsecas de extrinsecas e separa alucinacao de problemas de factualidade. Propoe avaliacao com geracao dinamica de conjuntos de teste.

<https://aclanthology.org/2025.acl-long.1176.pdf>

Roig, F. (2026). How Much Do LLMs Hallucinate in Document Q&A; Scenarios? A 172-Billion-Token Study. *arXiv:2603.08274*.

Estudo em larga escala que demonstra que nenhum benchmark existente aborda adequadamente a extracao de conhecimento de corpora de documentos longos. Introduz o framework RIKER para avaliacao em escala sem anotacao humana.

<https://arxiv.org/abs/2603.08274>

3.6 Extracao Estruturada de Documentos com LLMs

LLM-TKIE (2025). Large language model driven transferable key information extraction mechanism for nonstandardized tables. *Scientific Reports (Nature)*.

Propoe mecanismo que combina OCR com raciocinio semantico de LLMs para verificacao de completude e extracao de informacao-chave, organizando dados em formatos estruturados como JSON. Atinge F1-score de 80.9 no benchmark CORD sem fine-tuning.

<https://www.nature.com/articles/s41598-025-15627-z>

Bhattacharyya, A. et al. (2025). Information Extraction from Visually Rich Documents using LLM-based Organization of Documents into Independent Textual Segments. *ACL 2025*.

Propoe organizacao de documentos em segmentos textuais independentes antes da extracao, abordagem que pode mitigar o problema de perda de informacao em documentos longos.

<https://aclanthology.org/2025.acl-long.844.pdf>

3.7 Ferramentas de Extracao em Larga Escala

Google LangExtract (2025). Biblioteca open-source para extracao estruturada de documentos longos. Apache 2.0.

Resolve o problema 'needle-in-a-haystack' com chunking otimizado, processamento paralelo e multiplas passadas para maior recall. Testada em nosso projeto, porem inviavel no free tier da API Gemini devido ao volume de chamadas gerado.

<https://github.com/google/langextract>

4. Conexao com o Caso em Estudo

O problema enfrentado no desenvolvimento do Assistente de Editais e documentado na literatura como a intersecao de tres fenomenos: (1) alucinacao por infidelidade ao documento fonte (faithfulness hallucination), onde o modelo parafraseia e distorce informacoes em vez de extrai-las literalmente; (2) omissao seletiva em documentos longos (efeito 'Lost in the Middle'), onde informacoes no meio do contexto sao ignoradas; e (3) limitacoes na geracao de outputs estruturados complexos (JSON aninhado com muitos campos), onde o modelo tende a simplificar e resumir em vez de listar exaustivamente.

A literatura sugere que a mitigacao passa por estrategias de chunking inteligente com verificacao pos-extracao, uso de multiplas passadas (multi-pass extraction), e separacao da tarefa em subtarefas menores e mais focadas. Ferramentas como o LangExtract implementam essas estrategias, porem com custo computacional elevado que pode ser proibitivo em cenarios com restricoes de API.