

Laudo de Progresso: Extração Estruturada e Comportamento do Agente

Projeto Assistente de Editais — Branch develop — Abril 2026

1. Contexto

Este documento registra as ações realizadas e dificuldades identificadas no período entre o último push na branch develop e o estado atual do projeto. O laudo anterior documentou dois problemas na extração estruturada de editais via LLM: omissão seletiva de campos e parafrase distorcida de informações factuais. Duas tentativas de solução (H1 e H2) foram realizadas e falharam, conforme relatado no documento 'relatorio_tentativas_h2_h1.pdf'.

2. Ações Realizadas

2.1 Redução do escopo de extração

O prompt de extração foi reescrito para solicitar exclusivamente os dados gerais do edital e a ênfase de Ciência de Dados, descartando as demais ênfases. A motivação foi reduzir drasticamente o tamanho do output exigido do LLM. Editais com 13 a 24 ênfases geravam JSONs grandes que o modelo truncava ou resumia. Com foco em uma única ênfase, o output ficou pequeno e controlável.

2.2 Separação entre nomes de blocos e subtópicos

O conteúdo programático específico passou a ser extraído apenas como lista de nomes de blocos (ex: 'I - Matemática', 'IX - Processamento de Linguagem Natural'), sem os subtópicos detalhados. Os subtópicos permanecem acessíveis via busca semântica (RAG) no texto completo do edital. Essa separação reduziu o tamanho do output e eliminou a omissão: a extração do edital BNDES passou de 4/13 blocos para 13/13 blocos. O requisito básico também foi extraído de forma literal, corrigindo a parafrase distorcida observada anteriormente.

A decisão de manter subtópicos fora do JSON estruturado e delegá-los ao RAG é consistente com a observação de Liu et al. (2024) de que modelos de linguagem têm dificuldade em processar informações posicionadas no meio de contextos longos, tendendo a privilegiar o início e o fim. Ao reduzir o volume de informação solicitada no output, minimizamos a exposição a esse efeito.

2.3 Melhoria no comportamento do agente

O system prompt do agente foi ajustado para incluir a data atual e instruções explícitas de consultar a lista de editais cadastrados antes de responder, e de não desistir após uma única falha de tool. Essas instruções melhoraram parcialmente o comportamento, mas não resolveram os problemas estruturais descritos na seção seguinte.

3. Dificuldades Identificadas e Não Resolvidas

3.1 Fragilidade no lookup de editais

Todas as tools do agente utilizam correspondência por string (SQL LIKE) no campo 'orgão' para localizar editais. Essa abordagem é frágil por múltiplas razões: a função LOWER() do SQLite não normaliza acentos (ex: 'ECONOMICO' não corresponde a 'econômico'); abreviações do usuário (ex: 'BNDES') não correspondem ao nome completo no banco; e variações de grafia entre editais diferentes tornam o matching imprevisível. Em teste rastreado via LangSmith, o agente localizou o

edital do BNDES na listagem mas falhou ao consultar seus detalhes pelo nome.

3.2 Agente desiste na primeira falha

Quando uma tool retorna resultado vazio, o agente aceita a ausencia de dados e informa ao usuario que nao possui a informacao, sem tentar tools alternativas ou reformular a busca. Esse comportamento foi confirmado via LangSmith: ao perguntar 'quais editais estao com periodo de inscricao abertos?', o agente chamou info_edital com campo 'cronograma', recebeu 'Nenhum edital cadastrado' (devido ao problema 3.1) e encerrou sem tentar search_edital ou resumo_por_perfil.

A literatura sobre agentes baseados em LLM identifica esse padrao como uma limitacao conhecida. Huang et al. (2025) classificam como faithfulness hallucination os casos em que o modelo gera conteudo sintaticamente correto mas infiel aos dados disponiveis — neste caso, afirmar que nao ha informacao quando ela existe mas nao foi acessada corretamente.

3.3 Ausencia de inventario previo

O agente nao possui um passo obrigatorio de consultar quais editais existem no sistema antes de responder. Instrucoes no prompt sugerem essa pratica, mas nao a garantem. Como resultado, o agente frequentemente tenta acessar dados com identificadores incorretos ou incompletos.

4. Proximos Passos

O redesign planejado envolve: (1) substituicao de todos os lookups por string por lookups baseados em ID numerico do edital; (2) criacao de uma tool de listagem que retorna IDs e metadados, servindo como ponto de entrada obrigatorio; (3) tools que nunca retornam resultado vazio sem contexto — em caso de falha, retornam os dados disponiveis e sugerem proximos passos; (4) inclusao de um SOP (Standard Operating Procedure) no system prompt definindo a sequencia obrigatoria de acoes do agente.

5. Referencias

Liu, N. F. et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12, 157-173. DOI: 10.1162/tacl_a_00638.

Huang, L. et al. (2025). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Transactions on Information Systems*, 43(5), 1-55. DOI: 10.1145/3703155.