

Laudo de Desenvolvimento: Redesign de Tools e Verificacao de Progresso

Projeto Assistente de Editais — Branch develop — Abril 2026

1. Contexto

O sistema utiliza um agente baseado em LLM com ferramentas (tools) para responder perguntas sobre editais de concursos publicos. Laudos anteriores documentaram falhas na extracao estruturada (omissao seletiva e parafrase distorcida) e fragilidades no comportamento do agente (lookups por string, desistencia apos uma unica falha de tool, ausencia de inventario). Este laudo registra o redesign das tools e uma verificacao de progresso realizada com o edital BNDES 01/2024.

2. Redesign das Tools

As tools do agente foram redesenhadas com base em tres principios: (1) identificacao de editais por ID numerico em vez de correspondencia por string; (2) tools que nunca retornam resultado vazio sem contexto, sempre informando o que foi tentado e sugerindo proximos passos; (3) um procedimento operacional padrao (SOP) no system prompt definindo a sequencia obrigatoria de acoes do agente.

O agente passou a operar com quatro tools: **listar_editais** (ponto de entrada, retorna IDs e metadados compactos), **consultar_edital** (dados estruturados por ID e campo), **buscar_no_edital** (busca semantica via RAG, filtrada por ID) e **resumo_edital** (resumo pre-gerado focado em Ciencia de Dados). O fluxo imposto pelo SOP e: listar editais, identificar o ID correspondente, e entao consultar com a tool adequada.

3. Evolucao Qualitativa

A arquitetura anterior (RAG puro) apresentava problemas sistematicos documentados na literatura de Retrieval-Augmented Generation: perda de estrutura hierarquica do documento ao fragmenta-lo em chunks de tamanho fixo, ausencia de distincao entre secoes destinadas a diferentes enfases ou cargos, e retrieval baseado exclusivamente em similaridade semantica sem respeitar a logica documental. Na pratica, perguntas factuais retornavam trechos misturados de multiplas enfases, sem continuidade narrativa e sem distincao de contexto — um efeito bem documentado em sistemas RAG operando sobre documentos longos e multi-secao (Liu et al., 2024).

A nova arquitetura, combinando dados estruturados extraidos por LLM com busca semantica como complemento, reduziu significativamente esses problemas. Perguntas sobre salario, notas minimas, conteudo programatico, regras de prova e informacoes gerais passaram a ser respondidas com base em campos estruturados validados, sem depender de retrieval. O conteudo programatico especifico, que na extracao anterior retornava 4 de 13 blocos, agora retorna 13 de 13. O rastreamento via LangSmith confirmou que o fluxo de decisao do agente e significativamente mais coerente: o agente lista editais, identifica IDs e seleciona tools por tipo de consulta.

No entanto, os problemas de RAG nao foram eliminados. A contaminacao entre enfases ainda ocorre quando o agente seleciona a busca semantica para perguntas que possuem resposta nos dados estruturados — nesse caso, o RAG retorna trechos de outras enfases e o LLM os mistura na resposta. A minimizacao desse tipo de erro requer aperfeicoamento continuo, tanto na selecao de tool pelo agente quanto na qualidade dos chunks indexados.

4. Verificacao de Progresso

Uma verificacao pontual foi realizada com 10 perguntas cobrindo diferentes tipos de consulta (dados objetivos, regras detalhadas, conteudo programatico, comparacao temporal). As respostas de referencia foram extraidas manualmente do edital BNDES 01/2024. O objetivo nao foi realizar uma avaliacao formal, mas verificar se os erros documentados nos laudos anteriores foram mitigados e se o fluxo observado no LangSmith e mais coerente.

Pergunta	Resultado	Observacao
Salario	Correto	
Vagas por categoria	Incorreto	CN/PcD invertidos na base
Requisito de graduacao	Incorreto	RAG trouxe outra enfase
Inscricoes abertas	Incorreto	Nao comparou datas
Ingles elimina?	Correto	
Nota minima especificos	Correto	
Calculadora na prova	Correto	
Falta no dia da prova	Correto	
Blocos conteudo programatico	Correto	13/13 blocos
Cidades da prova	Incorreto	Nao chamou tool

Resultado: 6 acertos em 10 perguntas. Os erros se dividem em tres categorias: erro na base de dados (inversao de campos na extracao), selecao inadequada de tool (RAG em vez de dados estruturados) e ausencia de chamada de tool (agente responde sem consultar fonte).

5. Proximas Etapas

As seguintes direcoes foram identificadas pela equipe do projeto e complementadas por analise do modelo Claude Opus 4.6 (Anthropic).

5.1 Respostas com rastreabilidade de fonte

Direcao apontada pela equipe do projeto. Cada resposta do agente deve indicar a origem da informacao utilizada: tool chamada, campo consultado, ou trecho do edital referenciado. Isso permite ao usuario verificar a resposta e facilita avaliacoes sistematicas futuras. A implementacao envolve instrucao no system prompt e formatacao da saida, sem mudanca de arquitetura.

5.2 Validacao pos-extracao

Direcao identificada por analise do Opus 4.6. Erros como a inversao de campos CN/PcD persistem porque a extracao via LLM nao possui etapa de verificacao. Propoe-se uma validacao automatica que compare campos criticos extraidos contra o texto original usando uma segunda chamada ao LLM com pergunta direta (ex: 'quantas vagas PcD tem para Ciencia de Dados?'). Divergencias seriam sinalizadas para revisao. O custo e de uma chamada extra por campo critico, apenas durante a ingestao.

5.3 Refinamento da selecao de tool

Direcao identificada por analise do Opus 4.6. O agente selecionou busca semantica (RAG) para uma pergunta cujo dado estava disponivel nos campos estruturados. O problema reside nas descricoes das tools, que nao sao mutuamente exclusivas. A correcao proposta e tornar as

descrições explícitas sobre quais tipos de pergunta cada tool atende: `consultar_edital` para qualquer dado com campo no JSON, e `buscar_no_edital` exclusivamente para informações não cobertas pelos campos estruturados.

5.4 Metadata de ênfase nos chunks do RAG

Direção apontada pela equipe do projeto. A contaminação entre ênfases no RAG ocorre porque os chunks não possuem tag indicando a qual ênfase pertencem. Na indexação, cada chunk poderia receber classificação: 'geral' (aplicável a todos os candidatos), 'ciência de dados' (específico da ênfase) ou 'outra ênfase' (irrelevante). A busca filtraria por 'geral' e 'ciência de dados', eliminando trechos de outras áreas. Esta direção complementa o trabalho de filtragem por domínio tentado anteriormente (H2), porém aplicado no nível do chunk e não da página, evitando o descarte excessivo observado naquela tentativa.

6. Referências

Liu, N. F. et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12, 157-173. DOI: 10.1162/tacl_a_00638.