

Laudo de Investigação: Limitações do RAG Atual e Avaliação do Docling como Ferramenta de Estruturação

Projeto Assistente de Editais — Branch develop — Abril 2026

1. Contexto

O laudo comparativo anterior (04) mostrou que a arquitetura da branch develop (dados estruturados + RAG complementar) supera o RAG puro (6/10 vs 4/10 acertos), mas ainda apresenta erros residuais, entre eles: o agente ocasionalmente seleciona a busca semântica para perguntas cuja resposta está nos dados estruturados, e nesses casos o RAG contamina a resposta com trechos de outras ênfases. Este laudo documenta a investigação realizada para atacar o problema na sua origem — a estrutura dos chunks do RAG — e as direções avaliadas.

2. Diagnóstico do RAG atual

O pipeline de indexação (ingestion/rag.py) faz chunking de caracteres fixos (1000 caracteres, 200 de overlap) sobre o texto extraído com pdfplumber. Cada chunk recebe apenas três campos de metadata: `edital_id`, `orgao` e `chunk_index`. Esse esquema gera três problemas concretos:

2.1 Contaminação entre ênfases. Editais multi-ênfase (o BNDES 01/2024 tem 14 ênfases) possuem seções com vocabulário quase idêntico entre áreas distintas — requisitos, conteúdo programático, atribuições. Um chunk sobre requisitos de Administração é semanticamente muito próximo de um chunk sobre requisitos de Ciência de Dados. Sem metadata que identifique a ênfase, a busca vetorial não distingue. Isso se manifestou no laudo comparativo na pergunta 3 (requisito de graduação), onde o RAG puro mesclou requisitos de múltiplas áreas na resposta.

2.2 Ausência de rastreabilidade. Como o chunk carrega apenas índice sequencial, a resposta do agente não consegue citar página, seção ou contexto de origem da informação. Para um assistente que responde sobre documentos oficiais, essa é uma limitação prática relevante.

2.3 Recuperação de conteúdo tabular. Tabelas como a de vagas ("AC 11, PcD 3, CN 6") têm similaridade semântica baixíssima com perguntas formuladas em linguagem natural ("quantas vagas PcD tem?"). O chunking de caracteres fixos ainda pode fragmentar a tabela no meio, destruindo sua integridade. Esse é o tipo de informação que o RAG estruturalmente não recupera bem, independentemente do modelo de embedding.

3. Investigação do Docling

O Docling (IBM, licença MIT) foi identificado como ferramenta candidata para produzir uma representação intermediária do PDF que preservasse estrutura, páginas e tabelas — condições necessárias para construir metadata rica nos chunks. Uma conversão de teste foi executada sobre o edital BNDES 01/2024 (47 páginas).

3.1 O que o Docling entrega bem

Aspecto	Resultado
Cobertura de páginas	47/47 páginas identificadas
Blocos tipados	text (249), list_item (57), section_header (50), table (2), footnote (2)
Tabelas estruturadas	Tabela de vagas recuperada como objeto (15x9 células)
Metadado de origem	Cada bloco carrega referência à página de origem

A recuperação estruturada da tabela de vagas é particularmente relevante: esse é o dado que a extração via LLM no pipeline atual inverteu (CN/PcD trocados). Ler a tabela diretamente do output do Docling, sem passar por LLM, é uma via possível para eliminar essa classe de erro na ingestão.

3.2 O que o Docling não entrega

Hierarquia de headings. Todos os 50 headings detectados foram rotulados no nível 1. A hierarquia visual do documento (seções, subseções, sub-subseções) não é preservada pelo Docling — o que bate com relato externo de que a ferramenta é boa em estrutura bruta e tabelas, mas fraca em hierarquia temática.

Completeness de detecção. Headings são pulados de forma não determinística. No teste, a sequência identificada foi 2.1.1, 2.1.2, 2.1.3, 2.1.4, 2.1.5, 2.1.13 — oito ênfases intermediárias não foram marcadas como `section_header` e apareceram como `text` ou `list_item`. O conteúdo delas não foi perdido, mas o rótulo que o identificaria sim.

Consequência combinada. As duas limitações juntas inviabilizam derivar automaticamente do Docling uma árvore de seções do edital. Sem essa árvore, qualquer esquema de metadata que dependa de "a qual seção este chunk pertence" precisa de uma etapa adicional de reconstrução.

4. Direções avaliadas

Seis direções foram consideradas durante a discussão. A avaliação abaixo não é uma comparação formal — reflete o estado do raciocínio no momento da investigação e as preocupações práticas do projeto (robustez entre editais diferentes, custo operacional, complexidade de debug).

A. Classificação do chunk pelo próprio conteúdo. Cada chunk seria classificado por um LLM em geral/ciência_de_dados/outra_ênfase a partir do texto que ele contém, sem depender de heading pai. *Problema identificado:* conteúdos de outras áreas podem se parecer textualmente com Ciência de Dados (qualquer ênfase com componente quantitativo), e conteúdos comuns (ex: Língua Portuguesa) não se parecem com nenhuma ênfase. A classificação pelo conteúdo do chunk isolado tem ambiguidade inerente que não se resolve com prompt melhor.

B. Query expansion / reranking. Manter o RAG como está e adicionar uma segunda etapa de reordenação dos resultados. *Observação:* um rerank pela posição do texto no documento (proximidade estrutural) parece mais coerente que rerank por "importância" genérica. Direção considerada viável mas não explorada em profundidade — resolve qualidade de recuperação mas não ataca contaminação entre ênfases na raiz.

C. Indexação multi-representação. Indexar cada chunk várias vezes com representações diferentes (texto original, resumo, perguntas hipotéticas). *Avaliação:* complexidade de ingestão alta em relação ao ganho esperado. Não ataca o problema central de contaminação.

D. Agente de roteamento por tipo de pergunta. O agente classificaria a intenção da pergunta (requisito, prova, cronograma) e rotearia para fonte específica. *Avaliação:* direção limitada — não cobre perguntas que não caem em categorias pré-definidas, e tipos de pergunta variam entre editais.

E. Apostar em embedding de qualidade sem metadata. Manter a arquitetura atual com modelo melhor, top-k maior, cross-encoder. *Avaliação:* o laudo 04 já mostrou que o BGE-M3 com metadata pobre contamina respostas. Em um cenário futuro com N editais indexados, a contaminação crescerá — a busca traria trechos de editais diferentes e ênfases diferentes sem critério.

F. Reforçar a arquitetura atual sem mexer no RAG. Aceitar que o RAG é complementar e garantir que o JSON estruturado cubra o máximo possível. *Avaliação:* é o estado atual da branch develop. Os erros residuais documentados no laudo 04 são justamente os casos onde o JSON não cobre e o agente recorre ao RAG contaminado.

5. Restrições de projeto para a solução

Durante a discussão, três restrições foram explicitadas e limitam o espaço de soluções aceitáveis:

5.1 Não enviar para um edital específico. Reconstruir hierarquia por regex de numeração ("2.1.3 é filho de 2.1") funciona no BNDES mas assume formato que pode não existir em outros editais. Da mesma forma, assumir que existe o termo "ênfase" separando áreas é viés — outros editais podem usar "cargo", "perfil", "especialidade", "área de atuação" ou nenhuma separação explícita. A solução precisa funcionar em editais de formatos heterogêneos.

5.2 Solução automática. Inspeção manual ou correção manual pós-extração não são opções. O pipeline precisa ser executável sobre um edital novo sem intervenção do desenvolvedor.

5.3 Filtros de metadata sem sensibilidade a acentuação. Experiência prévia no projeto mostrou que SQLite e demais camadas não normalizam acentos em operações de comparação. Qualquer metadata usada como chave de filtro precisa ser construída de forma insensível a acento e caixa, sob risco de falsos negativos silenciosos no retrieval.

6. Estado atual

A investigação deixou o seguinte quadro consolidado. O Docling é útil como camada de entrada: preserva páginas, tipa blocos e recupera tabelas como objetos estruturados — três capacidades que o pdfplumber não oferece. Mas não entrega hierarquia de seções utilizável diretamente. Das seis direções consideradas, nenhuma foi adotada: A tem ambiguidade semântica inerente; B não ataca contaminação; C é desproporcional; D é restrito demais; E não escala para múltiplos editais; F é o estado atual cujos erros motivaram a investigação.

O diagnóstico permanece aberto. A próxima etapa do projeto envolverá a formulação de uma abordagem que contorne as três restrições acima simultaneamente.